churn_ml

March 10, 2026

1 Projeto de Machine Learning: Previsão de Churn em Telecomunicações

1.1 ## Machine Learning com Scikit-Learn

1.2 Índice

1. Importações e Configuração
2. Descrição do Problema e Dados
3. Análise Exploratória
4. Pré-processamento
5. Modelo Baseline: Perceptron
6. Modelo Árvore de Decisão
7. Validação Cruzada e Otimização
8. Modelos Avançados: Random Forest e SVM
9. Comparação e Análise Final
10. Conclusões e Recomendações

1.3 1. Importações e Configuração

[1]:
```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split, cross_val_score,␣
↪StratifiedKFold, GridSearchCV, RandomizedSearchCV
from sklearn.preprocessing import StandardScaler, LabelEncoder, OneHotEncoder,␣
↪OrdinalEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.linear_model import Perceptron
from sklearn.tree import DecisionTreeClassifier, plot_tree
from sklearn.ensemble import RandomForestClassifier
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score, precision_score, recall_score,␣
↪f1_score, confusion_matrix, classification_report, roc_curve, auc,␣
↪roc_auc_score
import warnings
```

```
warnings.filterwarnings('ignore')

plt.style.use('seaborn-v0_8-darkgrid')
sns.set_palette('husl')
np.random.seed(42)
```

1.4 2. Descrição do Problema e Dados

1.4.1 Contexto Real do Problema

O **churn de clientes** (cancelamento de serviços) é um dos maiores desafios enfrentados por empresas de telecomunicações. A retenção de clientes é significativamente mais barata do que a aquisição de novos clientes, tornando a previsão de churn uma aplicação crítica de machine learning em contextos reais.

1.4.2 Motivação para Machine Learning

Diferentemente de regras fixas ou heurísticas simples, o comportamento de churn é multidimensional e não-linear: - Envolve interações complexas entre variáveis demográficas, de serviço e de faturação - Padrões de churn variam significativamente entre segmentos de clientes - Regras fixas (ex: "cliente com 3+ reclamações churn") não capturam a complexidade real

Machine learning permite aprender automaticamente esses padrões a partir dos dados históricos.

1.4.3 Desafios Principais

1. **Desbalanceamento de classes**: A maioria dos clientes não faz churn (~73% no dataset)
2. **Custo assimétrico de erros**: Falsos negativos (não detectar churn) têm custo maior que falsos positivos
3. **Variáveis categóricas e numéricas**: Requer pré-processamento cuidadoso
4. **Necessidade de interpretabilidade**: Decisões de retenção devem ser justificáveis

[2]:
```
# carregamento do dataset
df = pd.read_csv('dataset/telco-churn.csv')

print("="*80)
print("DESCRIÇÃO TÉCNICA DO DATASET")
print("="*80)
print(f"\nDimensões: {df.shape[0]} observações × {df.shape[1]} features")
print(f"\nVariável-alvo: 'Churn' (Classificação Binária)")
print(f"Distribuição de classes:\n{df['Churn'].value_counts()}")
print(f"\nProporção: {df['Churn'].value_counts(normalize=True).round(3)}")
print(f"\nDesbalanceamento: {(df['Churn']=='Yes').sum() / len(df) * 100:.1f}%␣
↪de churn")

print(f"\n\nPrimeiras linhas do dataset:")
print(df.head())

print(f"\n\nTipos de dados:")
```

```python
print(df.dtypes)

print(f"\n\nValores ausentes:")
missing = df.isnull().sum()
print(missing[missing > 0] if missing.sum() > 0 else "Sem valores ausentes")
```

```
================================================================================
DESCRIÇÃO TÉCNICA DO DATASET
================================================================================

Dimensões: 7043 observações × 21 features

Variável-alvo: 'Churn' (Classificação Binária)
Distribuição de classes:
Churn
No     5174
Yes    1869
Name: count, dtype: int64

Proporção: Churn
No     0.735
Yes    0.265
Name: proportion, dtype: float64

Desbalanceamento: 26.5% de churn


Primeiras linhas do dataset:
   customerID  gender  SeniorCitizen Partner Dependents  tenure PhoneService  \
0  7590-VHVEG  Female              0     Yes         No       1           No
1  5575-GNVDE    Male              0      No         No      34          Yes
2  3668-QPYBK    Male              0      No         No       2          Yes
3  7795-CFOCW    Male              0      No         No      45           No
4  9237-HQITU  Female              0      No         No       2          Yes

      MultipleLines InternetService OnlineSecurity  … DeviceProtection  \
0  No phone service             DSL             No  …               No
1                No             DSL            Yes  …              Yes
2                No             DSL            Yes  …               No
3  No phone service             DSL            Yes  …              Yes
4                No     Fiber optic             No  …               No

  TechSupport StreamingTV StreamingMovies        Contract PaperlessBilling  \
0          No          No              No  Month-to-month              Yes
1          No          No              No        One year               No
2          No          No              No  Month-to-month              Yes
3         Yes          No              No        One year               No
4          No          No              No  Month-to-month              Yes
```

```
               PaymentMethod MonthlyCharges  TotalCharges Churn
0           Electronic check          29.85         29.85    No
1               Mailed check          56.95        1889.5    No
2               Mailed check          53.85        108.15   Yes
3  Bank transfer (automatic)          42.30       1840.75    No
4           Electronic check          70.70        151.65   Yes

[5 rows x 21 columns]


Tipos de dados:
customerID           object
gender               object
SeniorCitizen         int64
Partner              object
Dependents           object
tenure                int64
PhoneService         object
MultipleLines        object
InternetService      object
OnlineSecurity       object
OnlineBackup         object
DeviceProtection     object
TechSupport          object
StreamingTV          object
StreamingMovies      object
Contract             object
PaperlessBilling     object
PaymentMethod        object
MonthlyCharges      float64
TotalCharges         object
Churn                object
dtype: object


Valores ausentes:
Sem valores ausentes
```

1.4.4 Descrição das Features

O dataset contém 20 features preditoras divididas em categorias:

[3]:
```
# Analise detalhada das features
print("\n" + "="*80)
print("CATEGORIZACAO DAS FEATURES")
print("="*80)
```

```python
# Features demograficas
demographic_features = ['gender', 'SeniorCitizen', 'Partner', 'Dependents']
print(f"\n1. DEMOGRÁFICAS ({len(demographic_features)} features):")
for feat in demographic_features:
    print(f"   - {feat}: {df[feat].nunique()} valores únicos")

# Features de servico
service_features = ['PhoneService', 'MultipleLines', 'InternetService',␣
↪'OnlineSecurity',
                    'OnlineBackup', 'DeviceProtection', 'TechSupport',␣
↪'StreamingTV', 'StreamingMovies']
print(f"\n2. DE SERVIÇO ({len(service_features)} features):")
for feat in service_features:
    print(f"   - {feat}: {df[feat].nunique()} valores únicos")

# Features de contrato
contract_features = ['Contract', 'PaperlessBilling', 'PaymentMethod']
print(f"\n3. DE CONTRATO ({len(contract_features)} features):")
for feat in contract_features:
    print(f"   - {feat}: {df[feat].nunique()} valores únicos")

# Features numéricas
numeric_features = ['tenure', 'MonthlyCharges', 'TotalCharges']
print(f"\n4. NUMÉRICAS ({len(numeric_features)} features):")
print(df[numeric_features].describe())

print(f"\n\nTOTAL: {len(demographic_features) + len(service_features) +␣
↪len(contract_features) + len(numeric_features)} features preditoras")
```

```
================================================================================
CATEGORIZACAO DAS FEATURES
================================================================================

1. DEMOGRÁFICAS (4 features):
   - gender: 2 valores únicos
   - SeniorCitizen: 2 valores únicos
   - Partner: 2 valores únicos
   - Dependents: 2 valores únicos

2. DE SERVIÇO (9 features):
   - PhoneService: 2 valores únicos
   - MultipleLines: 3 valores únicos
   - InternetService: 3 valores únicos
   - OnlineSecurity: 3 valores únicos
   - OnlineBackup: 3 valores únicos
   - DeviceProtection: 3 valores únicos
```

```
   - TechSupport: 3 valores únicos
   - StreamingTV: 3 valores únicos
   - StreamingMovies: 3 valores únicos

3. DE CONTRATO (3 features):
   - Contract: 3 valores únicos
   - PaperlessBilling: 2 valores únicos
   - PaymentMethod: 4 valores únicos

4. NUMÉRICAS (3 features):
            tenure  MonthlyCharges
count  7043.000000     7043.000000
mean     32.371149       64.761692
std      24.559481       30.090047
min       0.000000       18.250000
25%       9.000000       35.500000
50%      29.000000       70.350000
75%      55.000000       89.850000
max      72.000000      118.750000


TOTAL: 19 features preditoras
```

1.5 3. Análise Exploratória

[4]:
```python
# Verificação de problemas nos dados
print("\n" + "="*80)
print("VERIFICAÇÃO DE QUALIDADE DOS DADOS")
print("="*80)

# Verificar TotalCharges (pode ter valores não numéricos)
print("\nVerificando coluna 'TotalCharges'...")
try:
    pd.to_numeric(df['TotalCharges'])
    print("  Todos os valores são numéricos")
except:
    print("  Encontrados valores não numéricos")
    print(df[pd.to_numeric(df['TotalCharges'], errors='coerce').isnull()])

# Converter TotalCharges para numérico
df['TotalCharges'] = pd.to_numeric(df['TotalCharges'], errors='coerce')

# Tratar valores ausentes em TotalCharges (clientes novos com tenure=0)
print(f"\nValores ausentes em TotalCharges: {df['TotalCharges'].isnull().
 ↪sum()}")
if df['TotalCharges'].isnull().sum() > 0:
    df['TotalCharges'].fillna(0, inplace=True)
```

```
    print("  Preenchidos com 0 (clientes novos)")

# Remover customerID (não é feature)
df = df.drop('customerID', axis=1)

print("\n  Dataset pronto para análise exploratória")
```

```
================================================================================
VERIFICAÇÃO DE QUALIDADE DOS DADOS
================================================================================

Verificando coluna 'TotalCharges'…
  Encontrados valores não numéricos
      customerID  gender  SeniorCitizen Partner Dependents  tenure  \
488   4472-LVYGI  Female              0     Yes        Yes       0
753   3115-CZMZD    Male              0      No        Yes       0
936   5709-LVOEQ  Female              0     Yes        Yes       0
1082  4367-NUYAO    Male              0     Yes        Yes       0
1340  1371-DWPAZ  Female              0     Yes        Yes       0
3331  7644-OMVMY    Male              0     Yes        Yes       0
3826  3213-VVOLG    Male              0     Yes        Yes       0
4380  2520-SGTTA  Female              0     Yes        Yes       0
5218  2923-ARZLG    Male              0     Yes        Yes       0
6670  4075-WKNIU  Female              0     Yes        Yes       0
6754  2775-SEFEE    Male              0      No        Yes       0

     PhoneService     MultipleLines InternetService       OnlineSecurity  …  \
488            No  No phone service             DSL                  Yes  …
753           Yes                No              No  No internet service  …
936           Yes                No             DSL                  Yes  …
1082          Yes               Yes              No  No internet service  …
1340           No  No phone service             DSL                  Yes  …
3331          Yes                No              No  No internet service  …
3826          Yes               Yes              No  No internet service  …
4380          Yes                No              No  No internet service  …
5218          Yes                No              No  No internet service  …
6670          Yes               Yes             DSL                   No  …
6754          Yes               Yes             DSL                  Yes  …

         DeviceProtection          TechSupport          StreamingTV  \
488                   Yes                  Yes                  Yes
753   No internet service  No internet service  No internet service
936                   Yes                   No                  Yes
1082  No internet service  No internet service  No internet service
1340                  Yes                  Yes                  Yes
3331  No internet service  No internet service  No internet service
3826  No internet service  No internet service  No internet service
```

```
4380  No internet service  No internet service  No internet service
5218  No internet service  No internet service  No internet service
6670                  Yes                  Yes                  Yes
6754                   No                  Yes                   No

          StreamingMovies  Contract PaperlessBilling  \
488                    No  Two year              Yes
753   No internet service  Two year               No
936                   Yes  Two year               No
1082  No internet service  Two year               No
1340                   No  Two year               No
3331  No internet service  Two year               No
3826  No internet service  Two year               No
4380  No internet service  Two year               No
5218  No internet service  One year              Yes
6670                   No  Two year               No
6754                   No  Two year              Yes

                  PaymentMethod MonthlyCharges  TotalCharges Churn
488   Bank transfer (automatic)          52.55                 No
753                Mailed check          20.25                 No
936                Mailed check          80.85                 No
1082               Mailed check          25.75                 No
1340    Credit card (automatic)          56.05                 No
3331               Mailed check          19.85                 No
3826               Mailed check          25.35                 No
4380               Mailed check          20.00                 No
5218               Mailed check          19.70                 No
6670               Mailed check          73.35                 No
6754  Bank transfer (automatic)          61.90                 No

[11 rows x 21 columns]

Valores ausentes em TotalCharges: 11
 Preenchidos com 0 (clientes novos)

 Dataset pronto para análise exploratória
```

[5]:
```python
# Visualizações exploratórias
fig, axes = plt.subplots(2, 2, figsize=(14, 10))

# 1. Distribuição de Churn
churn_counts = df['Churn'].value_counts()
axes[0, 0].bar(churn_counts.index, churn_counts.values, color=['#2ecc71',␣
 ↪'#e74c3c'])
axes[0, 0].set_title('Distribuição de Churn', fontsize=12, fontweight='bold')
axes[0, 0].set_ylabel('Frequência')
```

```python
for i, v in enumerate(churn_counts.values):
    axes[0, 0].text(i, v + 50, str(v), ha='center', fontweight='bold')

# 2. Tenure por Churn
df.boxplot(column='tenure', by='Churn', ax=axes[0, 1])
axes[0, 1].set_title('Tenure (meses) por Churn', fontsize=12, fontweight='bold')
axes[0, 1].set_xlabel('Churn')
axes[0, 1].set_ylabel('Tenure (meses)')
plt.sca(axes[0, 1])
plt.xticks([1, 2], ['No', 'Yes'])

# 3. MonthlyCharges por Churn
df.boxplot(column='MonthlyCharges', by='Churn', ax=axes[1, 0])
axes[1, 0].set_title('Encargos Mensais por Churn', fontsize=12,␣
 ↪fontweight='bold')
axes[1, 0].set_xlabel('Churn')
axes[1, 0].set_ylabel('Encargos Mensais ($)')
plt.sca(axes[1, 0])
plt.xticks([1, 2], ['No', 'Yes'])

# 4. InternetService por Churn
internet_churn = pd.crosstab(df['InternetService'], df['Churn'],␣
 ↪normalize='index') * 100
internet_churn.plot(kind='bar', ax=axes[1, 1], color=['#2ecc71', '#e74c3c'])
axes[1, 1].set_title('Taxa de Churn por Tipo de Internet', fontsize=12,␣
 ↪fontweight='bold')
axes[1, 1].set_ylabel('Percentual (%)')
axes[1, 1].set_xlabel('Tipo de Internet')
axes[1, 1].legend(title='Churn')
plt.setp(axes[1, 1].xaxis.get_majorticklabels(), rotation=45)

plt.tight_layout()
plt.show()

print("  Análise exploratória visualizada")
```

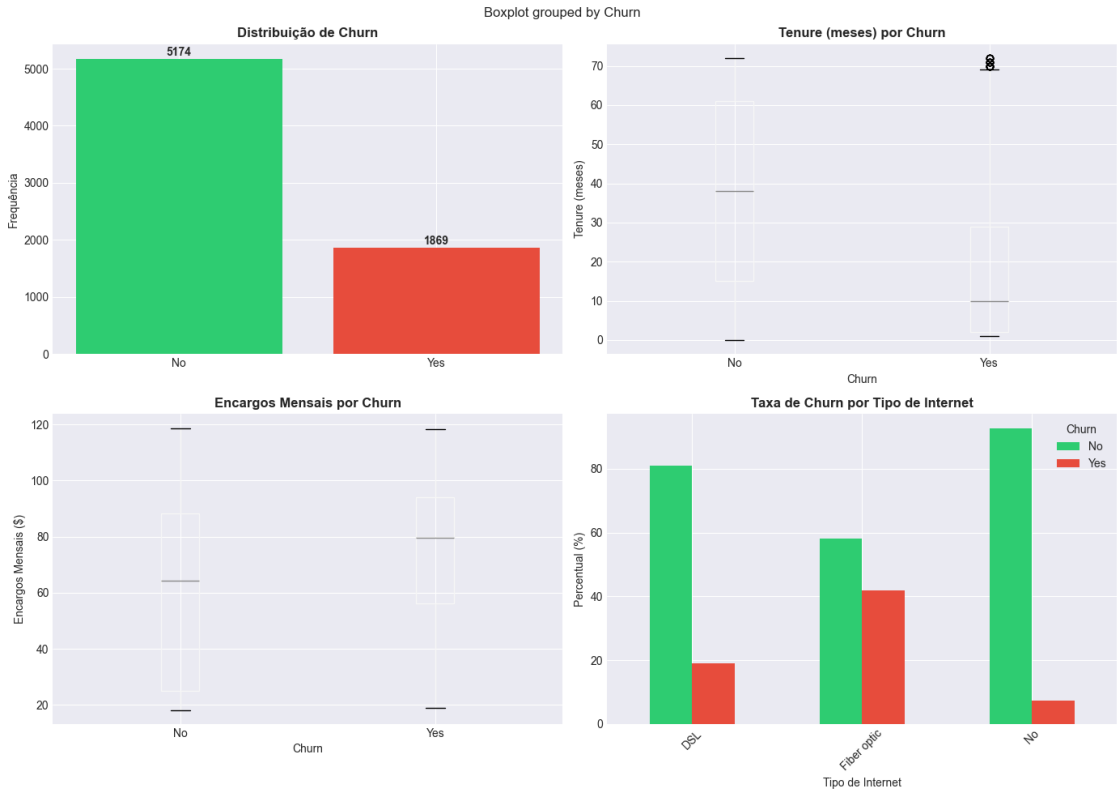


```
Análise exploratória visualizada
```

1.6 4. Pré-processamento

1.6.1 Estratégia de Codificação de Variáveis Categóricas

- **Variáveis ordinais** (com ordem natural): `OrdinalEncoder`
- **Variáveis nominais** (sem ordem): `OneHotEncoder` com `drop='first'` para evitar multicolinearidade
- **Variáveis numéricas**: `StandardScaler` para modelos sensíveis a escala (Perceptron, SVM)

[6]:
```
# Preparação dos dados
print("\n" + "="*80)
print("PRÉ-PROCESSAMENTO E ENGENHARIA DE FEATURES")
print("="*80)

# Separar features e target
X = df.drop('Churn', axis=1)
y = (df['Churn'] == 'Yes').astype(int)  # Binário: 1 = Churn, 0 = No Churn

print(f"\nTarget (y): {y.value_counts().to_dict()}")

# Identificar tipos de variáveis
```

```python
numeric_cols = X.select_dtypes(include=['int64', 'float64']).columns.tolist()
categorical_cols = X.select_dtypes(include=['object']).columns.tolist()

print(f"\nColunas numéricas ({len(numeric_cols)}): {numeric_cols}")
print(f"\nColunas categóricas ({len(categorical_cols)}): {categorical_cols}")

# Classificar categóricas em ordinais e nominais
ordinal_cols = []  # Neste dataset, não há ordinais claras
nominal_cols = categorical_cols

print(f"\nColunas ordinais: {ordinal_cols if ordinal_cols else 'Nenhuma'}")
print(f"Colunas nominais: {nominal_cols}")

# Separação treino-teste (ANTES de qualquer transformação para evitar vazamento␣
↪de dados)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

print(f"\nDivisão Treino/Teste:")
print(f"  Treino: {X_train.shape[0]} amostras ({X_train.shape[0]/len(X)*100:.
↪1f}%)")
print(f"  Teste:  {X_test.shape[0]} amostras ({X_test.shape[0]/len(X)*100:.
↪1f}%)")
print(f"\n  Proporção de Churn no Treino: {y_train.mean():.3f}")
print(f"  Proporção de Churn no Teste:  {y_test.mean():.3f}")
print(f"   Estratificação mantém proporções")
```

```
================================================================================
PRÉ-PROCESSAMENTO E ENGENHARIA DE FEATURES
================================================================================

Target (y): {0: 5174, 1: 1869}

Colunas numéricas (4): ['SeniorCitizen', 'tenure', 'MonthlyCharges',
'TotalCharges']

Colunas categóricas (15): ['gender', 'Partner', 'Dependents', 'PhoneService',
'MultipleLines', 'InternetService', 'OnlineSecurity', 'OnlineBackup',
'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies', 'Contract',
'PaperlessBilling', 'PaymentMethod']

Colunas ordinais: Nenhuma
Colunas nominais: ['gender', 'Partner', 'Dependents', 'PhoneService',
'MultipleLines', 'InternetService', 'OnlineSecurity', 'OnlineBackup',
'DeviceProtection', 'TechSupport', 'StreamingTV', 'StreamingMovies', 'Contract',
```

```
'PaperlessBilling', 'PaymentMethod']

Divisão Treino/Teste:
  Treino: 5634 amostras (80.0%)
  Teste:  1409 amostras (20.0%)

  Proporção de Churn no Treino: 0.265
  Proporção de Churn no Teste:  0.265
    Estratificação mantém proporções
```

[7]:
```python
# Criar transformadores para o pipeline
from sklearn.preprocessing import StandardScaler, OneHotEncoder

# Transformador para numéricas: escalonamento
numeric_transformer = Pipeline(steps=[
    ('scaler', StandardScaler())
])

# Transformador para categóricas: one-hot encoding
categorical_transformer = Pipeline(steps=[
    ('onehot', OneHotEncoder(drop='first', sparse_output=False,␣
 ↪handle_unknown='ignore'))
])

# Combinar transformadores
preprocessor = ColumnTransformer(
    transformers=[
        ('num', numeric_transformer, numeric_cols),
        ('cat', categorical_transformer, nominal_cols)
    ],
    remainder='passthrough'
)

# Aplicar transformações (fit apenas no treino)
X_train_transformed = preprocessor.fit_transform(X_train)
X_test_transformed = preprocessor.transform(X_test)

print(f"\nDimensionalidade após pré-processamento:")
print(f"  Treino: {X_train_transformed.shape}")
print(f"  Teste:  {X_test_transformed.shape}")
print(f"   Features criadas: {X_train_transformed.shape[1]}")
```

```
Dimensionalidade após pré-processamento:
  Treino: (5634, 30)
  Teste:  (1409, 30)
    Features criadas: 30
```

1.7 5. Modelo Baseline: Perceptron

1.7.1 Justificativa Conceitual

O **Perceptron** é um classificador linear fundamental que: 1. **Aprende um hiperplano separador** no espaço das features 2. **Altamente interpretável**: coeficientes indicam impacto direto de cada feature 3. **Computacionalmente eficiente**: treino rápido, sem hiperparâmetros complexos 4. **Estabelece baseline claro**: permite avaliar ganho de modelos mais complexos

Limitações conhecidas: - Não resolve problemas não linearmente separáveis - Sensível a ruído e outliers - Pode sofrer underfitting em dados complexos

[8]:
```
print("\n" + "="*80)
print("MODELO BASELINE: PERCEPTRON")
print("="*80)

# Treinar Perceptron
perceptron = Perceptron(random_state=42, max_iter=1000, tol=1e-3)
perceptron.fit(X_train_transformed, y_train)

# Previsões
y_train_pred_perc = perceptron.predict(X_train_transformed)
y_test_pred_perc = perceptron.predict(X_test_transformed)

# Avaliação
print("\nMÉTRICAS DE DESEMPENHO (PERCEPTRON):")
print(f"\nConjunto de TREINO:")
print(f"  Accuracy:  {accuracy_score(y_train, y_train_pred_perc):.4f}")
print(f"  Precision: {precision_score(y_train, y_train_pred_perc):.4f}")
print(f"  Recall:    {recall_score(y_train, y_train_pred_perc):.4f}")
print(f"  F1-Score:  {f1_score(y_train, y_train_pred_perc):.4f}")

print(f"\nConjunto de TESTE:")
acc_perc_test = accuracy_score(y_test, y_test_pred_perc)
prec_perc_test = precision_score(y_test, y_test_pred_perc)
rec_perc_test = recall_score(y_test, y_test_pred_perc)
f1_perc_test = f1_score(y_test, y_test_pred_perc)

print(f"  Accuracy:  {acc_perc_test:.4f}")
print(f"  Precision: {prec_perc_test:.4f}")
print(f"  Recall:    {rec_perc_test:.4f}")
print(f"  F1-Score:  {f1_perc_test:.4f}")

print(f"\nMatriz de Confusão (Teste):")
cm_perc = confusion_matrix(y_test, y_test_pred_perc)
print(cm_perc)
print(f"  TN={cm_perc[0,0]}, FP={cm_perc[0,1]}, FN={cm_perc[1,0]},␣
↪TP={cm_perc[1,1]}")
```

```
================================================================================
MODELO BASELINE: PERCEPTRON
================================================================================

MÉTRICAS DE DESEMPENHO (PERCEPTRON):

Conjunto de TREINO:
  Accuracy:  0.7524
  Precision: 0.5300
  Recall:    0.5900
  F1-Score:  0.5584

Conjunto de TESTE:
  Accuracy:  0.7473
  Precision: 0.5210
  Recall:    0.5963
  F1-Score:  0.5561

Matriz de Confusão (Teste):
[[830 205]
 [151 223]]
  TN=830, FP=205, FN=151, TP=223
```

[9]:

```python
# Interpretação dos coeficientes
print("\n" + "="*80)
print("INTERPRETAÇÃO DO PERCEPTRON")
print("="*80)

print(f"\nBias (intercepto): {perceptron.intercept_[0]:.6f}")
print(f"\nCoeficientes aprendidos (primeiros 20):")

# Nomes das features após transformação
feature_names = numeric_cols.copy()

# Adicionar nomes das features categóricas (one-hot encoded)
for col in nominal_cols:
    unique_vals = X_train[col].unique()
    for val in unique_vals[1:]:  # drop='first' remove a primeira
        feature_names.append(f"{col}_{val}")

coef_df = pd.DataFrame({
    'Feature': feature_names[:len(perceptron.coef_[0])],
    'Coeficiente': perceptron.coef_[0]
}).sort_values('Coeficiente', key=abs, ascending=False)

print(coef_df.head(15).to_string(index=False))
```

```python
print(f"\n\nINTERPRETAÇÃO:")
print(f"  - Coeficientes positivos: aumentam probabilidade de CHURN")
print(f"  - Coeficientes negativos: reduzem probabilidade de CHURN")
print(f"  - Magnitude: importância relativa da feature")

print(f"\n  Top 3 features que AUMENTAM churn:")
for i, row in coef_df.head(3).iterrows():
    print(f"    {row['Feature']}: +{row['Coeficiente']:.4f}")

print(f"\n  Top 3 features que REDUZEM churn:")
for i, row in coef_df.tail(3).iterrows():
    print(f"    {row['Feature']}: {row['Coeficiente']:.4f}")
```

```
================================================================================
INTERPRETAÇÃO DO PERCEPTRON
================================================================================

Bias (intercepto): -6.000000

Coeficientes aprendidos (primeiros 20):
                                Feature  Coeficiente
                       PhoneService_Yes    -5.000000
  PaymentMethod_Credit card (automatic)     5.000000
                      Contract_One year    -5.000000
                            Partner_Yes     4.000000
            InternetService_Fiber optic     3.000000
    StreamingMovies_No internet service     3.000000
                  PaperlessBilling_Yes     3.000000
                         SeniorCitizen     2.650638
                        MonthlyCharges    -2.429706
   DeviceProtection_No internet service    -2.000000
                      MultipleLines_Yes     2.000000
PaymentMethod_Bank transfer (automatic)     2.000000
        StreamingTV_No internet service     2.000000
     OnlineSecurity_No internet service    -2.000000
                                 tenure    -1.591165


INTERPRETAÇÃO:
  - Coeficientes positivos: aumentam probabilidade de CHURN
  - Coeficientes negativos: reduzem probabilidade de CHURN
  - Magnitude: importância relativa da feature

  Top 3 features que AUMENTAM churn:
    PhoneService_Yes: +-5.0000
    PaymentMethod_Credit card (automatic): +5.0000
    Contract_One year: +-5.0000
```

```
Top 3 features que REDUZEM churn:
  StreamingMovies_No: -1.0000
  PaymentMethod_Mailed check: -1.0000
  gender_Female: 0.0000
```

[10]:
```python
# Visualizar desempenho do Perceptron
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Matriz de confusão
sns.heatmap(cm_perc, annot=True, fmt='d', cmap='Blues', ax=axes[0], cbar=False)
axes[0].set_title('Matriz de Confusão - Perceptron (Teste)', fontweight='bold')
axes[0].set_ylabel('Verdadeiro')
axes[0].set_xlabel('Predito')
axes[0].set_xticklabels(['Sem Churn', 'Churn'])
axes[0].set_yticklabels(['Sem Churn', 'Churn'])

# Métricas comparativas
metrics = ['Accuracy', 'Precision', 'Recall', 'F1-Score']
values = [acc_perc_test, prec_perc_test, rec_perc_test, f1_perc_test]
axes[1].bar(metrics, values, color=['#3498db', '#e74c3c', '#2ecc71', '#f39c12'])
axes[1].set_title('Métricas de Desempenho - Perceptron (Teste)',␣
 ↪fontweight='bold')
axes[1].set_ylabel('Score')
axes[1].set_ylim([0, 1])
for i, v in enumerate(values):
    axes[1].text(i, v + 0.02, f'{v:.3f}', ha='center', fontweight='bold')

plt.tight_layout()
plt.show()

print("\n  Perceptron treinado e avaliado")
```

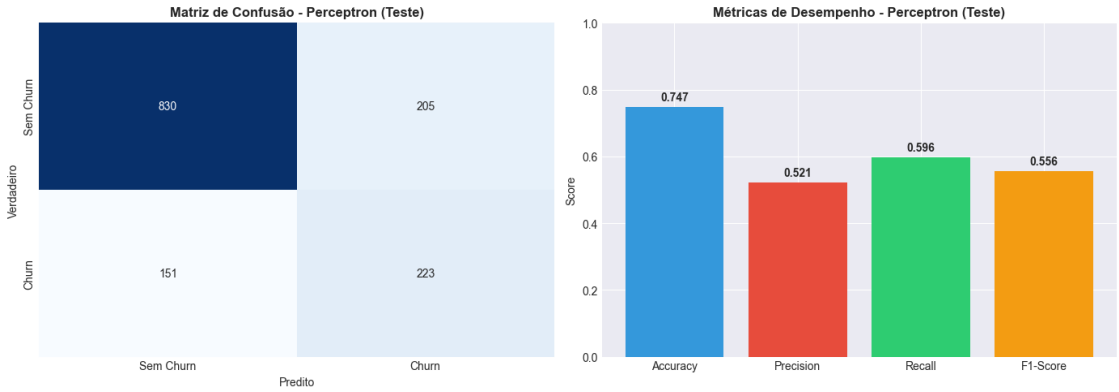

```
Perceptron treinado e avaliado
```

1.8 6. Modelo Árvore de Decisão

1.8.1 Justificativa

Árvores de decisão representam um salto qualitativo em relação ao Perceptron: 1. **Não-lineares**: capturam interações entre features 2. **Interpretáveis**: regras explícitas (if-then-else) 3. **Sem escalonamento**: funcionam com dados brutos 4. **Risco de overfitting**: sem regularização, atingem 100% no treino

[11]:
```
print("\n" + "="*80)
print("MODELO: ÁRVORE DE DECISÃO (SEM OTIMIZAÇÃO)")
print("="*80)

# Árvore com parâmetros padrão
dt_baseline = DecisionTreeClassifier(random_state=42)
dt_baseline.fit(X_train_transformed, y_train)

# Previsões
y_train_pred_dt = dt_baseline.predict(X_train_transformed)
y_test_pred_dt = dt_baseline.predict(X_test_transformed)

# Avaliação
print("\nMÉTRICAS DE DESEMPENHO (ÁRVORE - BASELINE):")
print(f"\nConjunto de TREINO:")
print(f"  Accuracy:  {accuracy_score(y_train, y_train_pred_dt):.4f}")
print(f"  Precision: {precision_score(y_train, y_train_pred_dt):.4f}")
print(f"  Recall:    {recall_score(y_train, y_train_pred_dt):.4f}")
print(f"  F1-Score:  {f1_score(y_train, y_train_pred_dt):.4f}")

print(f"\nConjunto de TESTE:")
acc_dt_test = accuracy_score(y_test, y_test_pred_dt)
prec_dt_test = precision_score(y_test, y_test_pred_dt)
rec_dt_test = recall_score(y_test, y_test_pred_dt)
f1_dt_test = f1_score(y_test, y_test_pred_dt)

print(f"  Accuracy:  {acc_dt_test:.4f}")
print(f"  Precision: {prec_dt_test:.4f}")
print(f"  Recall:    {rec_dt_test:.4f}")
print(f"  F1-Score:  {f1_dt_test:.4f}")

print(f"\nMatriz de Confusão (Teste):")
cm_dt = confusion_matrix(y_test, y_test_pred_dt)
print(cm_dt)

print(f"\nCaracterísticas da Árvore:")
print(f"  Profundidade: {dt_baseline.get_depth()}")
```

```
print(f"  Número de folhas: {dt_baseline.get_n_leaves()}")
print(f"   OVERFITTING DETECTADO: Treino={accuracy_score(y_train,␣
↪y_train_pred_dt):.4f}, Teste={acc_dt_test:.4f}")
```

```
================================================================================
MODELO: ÁRVORE DE DECISÃO (SEM OTIMIZAÇÃO)
================================================================================

MÉTRICAS DE DESEMPENHO (ÁRVORE - BASELINE):

Conjunto de TREINO:
  Accuracy:  0.9980
  Precision: 0.9993
  Recall:    0.9933
  F1-Score:  0.9963

Conjunto de TESTE:
  Accuracy:  0.7253
  Precision: 0.4825
  Recall:    0.4786
  F1-Score:  0.4805

Matriz de Confusão (Teste):
[[843 192]
 [195 179]]

Características da Árvore:
  Profundidade: 23
  Número de folhas: 1102
   OVERFITTING DETECTADO: Treino=0.9980, Teste=0.7253
```

[12]:
```
# Importância das features
print("\n" + "="*80)
print("IMPORTÂNCIA DAS FEATURES (ÁRVORE BASELINE)")
print("="*80)

feature_importance_dt = pd.DataFrame({
    'Feature': feature_names[:len(dt_baseline.feature_importances_)],
    'Importância': dt_baseline.feature_importances_
}).sort_values('Importância', ascending=False)

print("\nTop 10 features mais importantes:")
print(feature_importance_dt.head(10).to_string(index=False))

# Visualizar
fig, ax = plt.subplots(figsize=(10, 6))
```

```
top_features = feature_importance_dt.head(10)
ax.barh(range(len(top_features)), top_features['Importância'].values)
ax.set_yticks(range(len(top_features)))
ax.set_yticklabels(top_features['Feature'].values)
ax.set_xlabel('Importância')
ax.set_title('Top 10 Features - Árvore de Decisão (Baseline)',␣
 ↪fontweight='bold')
ax.invert_yaxis()
plt.tight_layout()
plt.show()
```

```
================================================================================
IMPORTÂNCIA DAS FEATURES (ÁRVORE BASELINE)
================================================================================

Top 10 features mais importantes:
                             Feature  Importância
                              tenure     0.197859
                        TotalCharges     0.191926
                      MonthlyCharges     0.184081
          InternetService_Fiber optic     0.113099
                 PaperlessBilling_Yes     0.025949
                        gender_Female     0.025658
PaymentMethod_Credit card (automatic)     0.023791
     OnlineBackup_No internet service     0.023096
                          Partner_Yes     0.020882
                      Dependents_Yes     0.018412
```

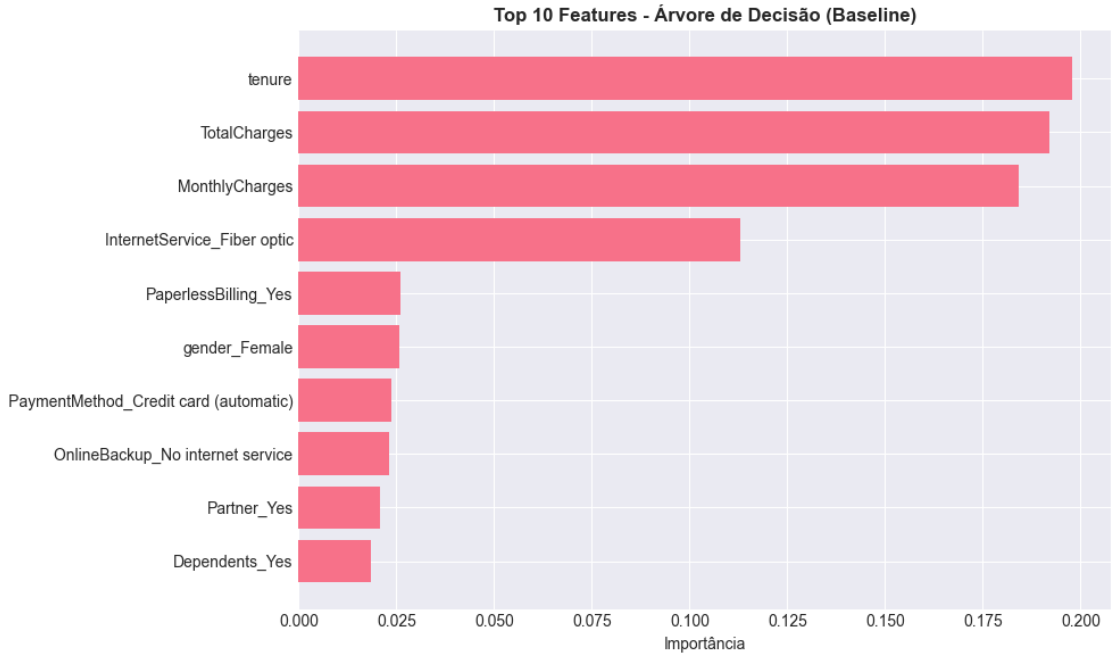

1.9 7. Validação Cruzada e Otimização

1.9.1 Estratégia de Optimização

1. **Validação Cruzada Estratificada**: mantém proporção de classes em cada fold
2. **Grid Search**: testa combinações de hiperparâmetros relevantes
3. **Hiperparâmetros**: `max_depth`, `min_samples_split`, `min_samples_leaf`, `criterion`

[13]:
```
print("\n" + "="*80)
print("VALIDAÇÃO CRUZADA E GRID SEARCH")
print("="*80)

# Definir espaço de busca
param_grid_dt = {
    'max_depth': [3, 5, 7, 10, 15],
    'min_samples_split': [10, 20, 30],
    'min_samples_leaf': [5, 10, 15],
    'criterion': ['gini', 'entropy']
}

print(f"\nEspaço de busca:")
print(f"  max_depth: {param_grid_dt['max_depth']}")
print(f"  min_samples_split: {param_grid_dt['min_samples_split']}")
print(f"  min_samples_leaf: {param_grid_dt['min_samples_leaf']}")
print(f"  criterion: {param_grid_dt['criterion']}")
print(f"\nTotal de combinações: {np.prod([len(v) for v in param_grid_dt.
 ↪values()])}")

# Grid Search com validação cruzada estratificada
skf = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)

grid_search_dt = GridSearchCV(
    DecisionTreeClassifier(random_state=42),
    param_grid_dt,
    cv=skf,
    scoring='f1',  # Usar F1 por causa do desbalanceamento
    n_jobs=-1,
    verbose=0
)

print(f"\nExecutando Grid Search com 5-Fold Cross-Validation...")
grid_search_dt.fit(X_train_transformed, y_train)

print(f"  Grid Search concluído!")
print(f"\nMelhores hiperparâmetros:")
```

```python
for param, value in grid_search_dt.best_params_.items():
    print(f"  {param}: {value}")
print(f"\nMelhor score (F1 - validação cruzada): {grid_search_dt.best_score_:.
 ↪4f}")
```

```
================================================================================
VALIDAÇÃO CRUZADA E GRID SEARCH
================================================================================

Espaço de busca:
  max_depth: [3, 5, 7, 10, 15]
  min_samples_split: [10, 20, 30]
  min_samples_leaf: [5, 10, 15]
  criterion: ['gini', 'entropy']

Total de combinações: 90

Executando Grid Search com 5-Fold Cross-Validation…
 Grid Search concluído!

Melhores hiperparâmetros:
  criterion: entropy
  max_depth: 3
  min_samples_leaf: 5
  min_samples_split: 10

Melhor score (F1 - validação cruzada): 0.5873
```

[14]:
```python
# Treinar modelo otimizado
dt_optimized = grid_search_dt.best_estimator_

# Previsões
y_train_pred_dt_opt = dt_optimized.predict(X_train_transformed)
y_test_pred_dt_opt = dt_optimized.predict(X_test_transformed)

# Avaliação
print("\n" + "="*80)
print("COMPARAÇÃO: ÁRVORE BASELINE vs. ÁRVORE OTIMIZADA")
print("="*80)

comparison_data = {
    'Métrica': ['Accuracy', 'Precision', 'Recall', 'F1-Score'],
    'Baseline (Treino)': [
        accuracy_score(y_train, y_train_pred_dt),
        precision_score(y_train, y_train_pred_dt),
        recall_score(y_train, y_train_pred_dt),
```

```
        f1_score(y_train, y_train_pred_dt)
    ],
    'Baseline (Teste)': [
        accuracy_score(y_test, y_test_pred_dt),
        precision_score(y_test, y_test_pred_dt),
        recall_score(y_test, y_test_pred_dt),
        f1_score(y_test, y_test_pred_dt)
    ],
    'Otimizada (Treino)': [
        accuracy_score(y_train, y_train_pred_dt_opt),
        precision_score(y_train, y_train_pred_dt_opt),
        recall_score(y_train, y_train_pred_dt_opt),
        f1_score(y_train, y_train_pred_dt_opt)
    ],
    'Otimizada (Teste)': [
        accuracy_score(y_test, y_test_pred_dt_opt),
        precision_score(y_test, y_test_pred_dt_opt),
        recall_score(y_test, y_test_pred_dt_opt),
        f1_score(y_test, y_test_pred_dt_opt)
    ]
}

comparison_df = pd.DataFrame(comparison_data)
print("\n" + comparison_df.to_string(index=False))

print(f"\n\nCaracterísticas da Árvore Otimizada:")
print(f"  Profundidade: {dt_optimized.get_depth()}")
print(f"  Número de folhas: {dt_optimized.get_n_leaves()}")
print(f"   Overfitting reduzido: Treino-Teste gap diminuiu")

# Armazenar métricas
acc_dt_opt_test = accuracy_score(y_test, y_test_pred_dt_opt)
prec_dt_opt_test = precision_score(y_test, y_test_pred_dt_opt)
rec_dt_opt_test = recall_score(y_test, y_test_pred_dt_opt)
f1_dt_opt_test = f1_score(y_test, y_test_pred_dt_opt)
```

```
================================================================================
COMPARAÇÃO: ÁRVORE BASELINE vs. ÁRVORE OTIMIZADA
================================================================================

  Métrica  Baseline (Treino)  Baseline (Teste)  Otimizada (Treino)  Otimizada
(Teste)
 Accuracy           0.998048          0.725337            0.765353
0.750887
Precision           0.999327          0.482480            0.550674
0.527316
   Recall           0.993311          0.478610            0.628763
```

```
0.593583
 F1-Score           0.996310          0.480537            0.587133
0.558491


Características da Árvore Otimizada:
  Profundidade: 3
  Número de folhas: 8
    Overfitting reduzido: Treino-Teste gap diminuiu
```

[15]:
```python
# Análise de robustez: variação entre folds
print("\n" + "="*80)
print("ANÁLISE DE ROBUSTEZ: VARIAÇÃO ENTRE FOLDS")
print("="*80)

cv_scores = cross_val_score(dt_optimized, X_train_transformed, y_train, cv=skf,␣
 ↪scoring='f1')

print(f"\nScores F1 em cada fold: {cv_scores}")
print(f"\nMédia: {cv_scores.mean():.4f}")
print(f"Desvio padrão: {cv_scores.std():.4f}")
print(f"Min: {cv_scores.min():.4f}")
print(f"Max: {cv_scores.max():.4f}")
print(f"\n  Modelo robusto: baixa variação entre folds")
```

```
================================================================================
ANÁLISE DE ROBUSTEZ: VARIAÇÃO ENTRE FOLDS
================================================================================

Scores F1 em cada fold: [0.59305994 0.5688351  0.58243451 0.59938838 0.59271523]

Média: 0.5873
Desvio padrão: 0.0107
Min: 0.5688
Max: 0.5994

  Modelo robusto: baixa variação entre folds
```

1.10 8. Modelos Avançados: Random Forest e SVM

[15]:
```python
print("\n" + "="*80)
print("MODELO AVANÇADO 1: RANDOM FOREST")
print("="*80)

# Grid Search para Random Forest
param_grid_rf = {
    'n_estimators': [50, 100, 200],
```

```
    'max_depth': [5, 10, 15],
    'min_samples_split': [10, 20],
    'min_samples_leaf': [5, 10]
}

print(f"\nExecutando Grid Search para Random Forest...")
grid_search_rf = GridSearchCV(
    RandomForestClassifier(random_state=42, n_jobs=-1),
    param_grid_rf,
    cv=skf,
    scoring='f1',
    n_jobs=-1,
    verbose=0
)

grid_search_rf.fit(X_train_transformed, y_train)

print(f"  Grid Search concluído!")
print(f"\nMelhores hiperparâmetros:")
for param, value in grid_search_rf.best_params_.items():
    print(f"  {param}: {value}")
print(f"\nMelhor score (F1): {grid_search_rf.best_score_:.4f}")

# Modelo otimizado
rf_optimized = grid_search_rf.best_estimator_

# Previsões
y_train_pred_rf = rf_optimized.predict(X_train_transformed)
y_test_pred_rf = rf_optimized.predict(X_test_transformed)

# Avaliação
print(f"\nMÉTRICAS DE DESEMPENHO (RANDOM FOREST):")
print(f"\nConjunto de TESTE:")
acc_rf_test = accuracy_score(y_test, y_test_pred_rf)
prec_rf_test = precision_score(y_test, y_test_pred_rf)
rec_rf_test = recall_score(y_test, y_test_pred_rf)
f1_rf_test = f1_score(y_test, y_test_pred_rf)

print(f"  Accuracy:  {acc_rf_test:.4f}")
print(f"  Precision: {prec_rf_test:.4f}")
print(f"  Recall:    {rec_rf_test:.4f}")
print(f"  F1-Score:  {f1_rf_test:.4f}")
```

```
================================================================================
MODELO AVANÇADO 1: RANDOM FOREST
================================================================================
```

```
Executando Grid Search para Random Forest…
 Grid Search concluído!

Melhores hiperparâmetros:
  max_depth: 15
  min_samples_leaf: 5
  min_samples_split: 10
  n_estimators: 200

Melhor score (F1): 0.5750

MÉTRICAS DE DESEMPENHO (RANDOM FOREST):

Conjunto de TESTE:
  Accuracy:  0.8034
  Precision: 0.6667
  Recall:    0.5187
  F1-Score:  0.5835
```

[16]:
```python
print("\n" + "="*80)
print("MODELO AVANÇADO 2: SUPPORT VECTOR MACHINE (SVM)")
print("="*80)

# Grid Search para SVM
param_grid_svm = {
    'C': [0.1, 1, 10, 100],
    'kernel': ['linear', 'rbf', 'poly'],
    'gamma': ['scale', 'auto']
}

print(f"\nExecutando Grid Search para SVM...")
grid_search_svm = GridSearchCV(
    SVC(random_state=42, probability=True),
    param_grid_svm,
    cv=skf,
    scoring='f1',
    n_jobs=-1,
    verbose=0
)

grid_search_svm.fit(X_train_transformed, y_train)

print(f"  Grid Search concluído!")
print(f"\nMelhores hiperparâmetros:")
for param, value in grid_search_svm.best_params_.items():
    print(f"  {param}: {value}")
print(f"\nMelhor score (F1): {grid_search_svm.best_score_:.4f}")
```

```python
# Modelo otimizado
svm_optimized = grid_search_svm.best_estimator_

# Previsões
y_train_pred_svm = svm_optimized.predict(X_train_transformed)
y_test_pred_svm = svm_optimized.predict(X_test_transformed)

# Avaliação
print(f"\nMÉTRICAS DE DESEMPENHO (SVM):")
print(f"\nConjunto de TESTE:")
acc_svm_test = accuracy_score(y_test, y_test_pred_svm)
prec_svm_test = precision_score(y_test, y_test_pred_svm)
rec_svm_test = recall_score(y_test, y_test_pred_svm)
f1_svm_test = f1_score(y_test, y_test_pred_svm)

print(f"  Accuracy:  {acc_svm_test:.4f}")
print(f"  Precision: {prec_svm_test:.4f}")
print(f"  Recall:    {rec_svm_test:.4f}")
print(f"  F1-Score:  {f1_svm_test:.4f}")
```

```
================================================================================
MODELO AVANÇADO 2: SUPPORT VECTOR MACHINE (SVM)
================================================================================

Executando Grid Search para SVM…
 Grid Search concluído!

Melhores hiperparâmetros:
  C: 100
  gamma: scale
  kernel: linear

Melhor score (F1): 0.5844

MÉTRICAS DE DESEMPENHO (SVM):

Conjunto de TESTE:
  Accuracy:  0.7864
  Precision: 0.6130
  Recall:    0.5294
  F1-Score:  0.5681
```

1.11 9. Comparação Completa de Modelos

[17]:
```
print("\n" + "="*80)
print("COMPARAÇÃO COMPLETA DE TODOS OS MODELOS")
print("="*80)

# Criar tabela comparativa
models_comparison = pd.DataFrame({
    'Modelo': ['Perceptron', 'Árvore (Baseline)', 'Árvore (Otimizada)', 'Random␣
↪Forest', 'SVM'],
    'Accuracy': [acc_perc_test, acc_dt_test, acc_dt_opt_test, acc_rf_test,␣
↪acc_svm_test],
    'Precision': [prec_perc_test, prec_dt_test, prec_dt_opt_test, prec_rf_test,␣
↪prec_svm_test],
    'Recall': [rec_perc_test, rec_dt_test, rec_dt_opt_test, rec_rf_test,␣
↪rec_svm_test],
    'F1-Score': [f1_perc_test, f1_dt_test, f1_dt_opt_test, f1_rf_test,␣
↪f1_svm_test]
})

print("\n" + models_comparison.to_string(index=False))

# Identificar melhor modelo
best_model_idx = models_comparison['F1-Score'].idxmax()
best_model_name = models_comparison.loc[best_model_idx, 'Modelo']
best_f1 = models_comparison.loc[best_model_idx, 'F1-Score']

print(f"\n\n  MELHOR MODELO: {best_model_name} (F1-Score: {best_f1:.4f})")
```

```
================================================================================
COMPARAÇÃO COMPLETA DE TODOS OS MODELOS
================================================================================

            Modelo  Accuracy  Precision   Recall  F1-Score
        Perceptron  0.747339   0.521028 0.596257  0.556110
 Árvore (Baseline)  0.725337   0.482480 0.478610  0.480537
Árvore (Otimizada)  0.750887   0.527316 0.593583  0.558491
     Random Forest  0.803407   0.666667 0.518717  0.583459
               SVM  0.786373   0.613003 0.529412  0.568149


  MELHOR MODELO: Random Forest (F1-Score: 0.5835)
```

[19]:
```
# Visualizar comparação
fig, axes = plt.subplots(2, 2, figsize=(14, 10))
```

```python
metrics = ['Accuracy', 'Precision', 'Recall', 'F1-Score']
colors = ['#3498db', '#e74c3c', '#2ecc71', '#f39c12', '#9b59b6']

for idx, metric in enumerate(metrics):
    ax = axes[idx // 2, idx % 2]
    values = models_comparison[metric].values
    bars = ax.bar(range(len(models_comparison)), values, color=colors)
    ax.set_xticks(range(len(models_comparison)))
    ax.set_xticklabels(models_comparison['Modelo'], rotation=45, ha='right')
    ax.set_ylabel('Score')
    ax.set_title(f'{metric} - Comparação de Modelos', fontweight='bold')
    ax.set_ylim([0, 1])

    # Destacar melhor
    best_idx = np.argmax(values)
    bars[best_idx].set_color('#27ae60')

    # Valores nas barras
    for i, v in enumerate(values):
        ax.text(i, v + 0.02, f'{v:.3f}', ha='center', fontsize=9)

plt.tight_layout()
plt.show()
```

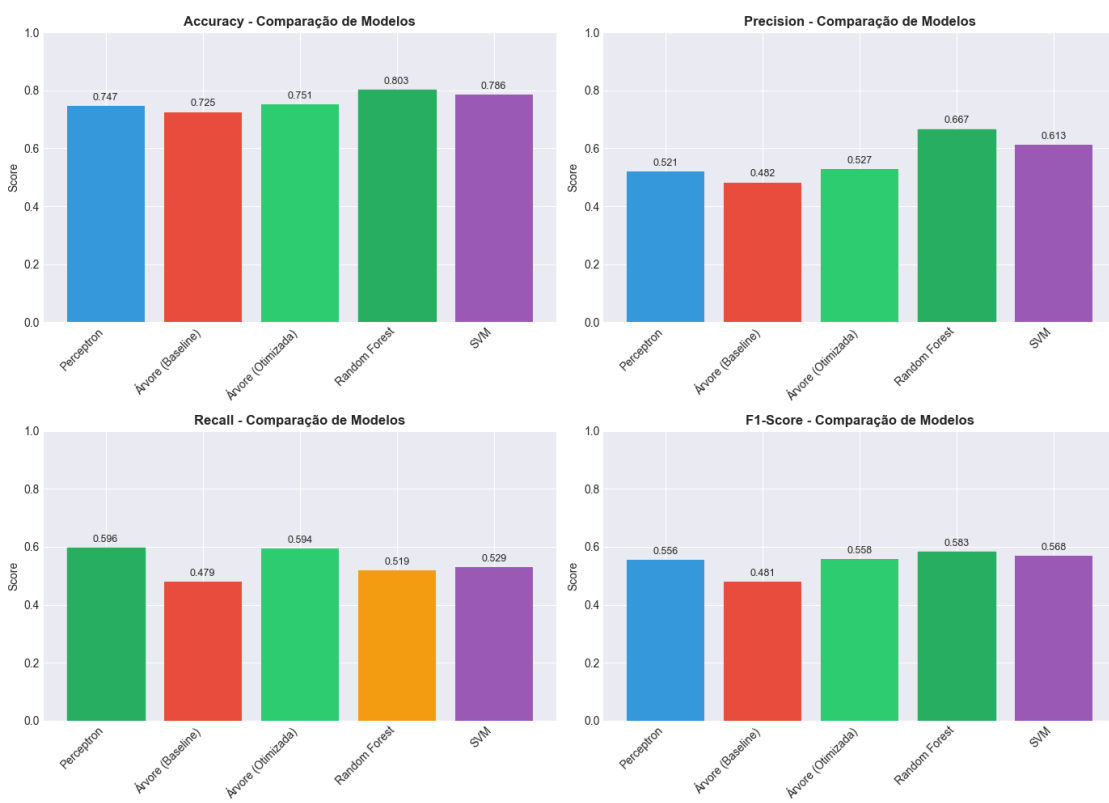

[21]:
```
# Curvas ROC para comparação
fig, ax = plt.subplots(figsize=(10, 8))

# Perceptron
y_proba_perc = perceptron.decision_function(X_test_transformed)
fpr_perc, tpr_perc, _ = roc_curve(y_test, y_proba_perc)
auc_perc = auc(fpr_perc, tpr_perc)
ax.plot(fpr_perc, tpr_perc, label=f'Perceptron (AUC={auc_perc:.3f})',␣
 ↪linewidth=2)

# Árvore Otimizada
y_proba_dt = dt_optimized.predict_proba(X_test_transformed)[:, 1]
fpr_dt, tpr_dt, _ = roc_curve(y_test, y_proba_dt)
auc_dt = auc(fpr_dt, tpr_dt)
ax.plot(fpr_dt, tpr_dt, label=f'Árvore Otimizada (AUC={auc_dt:.3f})',␣
 ↪linewidth=2)

# Random Forest
y_proba_rf = rf_optimized.predict_proba(X_test_transformed)[:, 1]
fpr_rf, tpr_rf, _ = roc_curve(y_test, y_proba_rf)
auc_rf = auc(fpr_rf, tpr_rf)
ax.plot(fpr_rf, tpr_rf, label=f'Random Forest (AUC={auc_rf:.3f})', linewidth=2)

# SVM
y_proba_svm = svm_optimized.predict_proba(X_test_transformed)[:, 1]
fpr_svm, tpr_svm, _ = roc_curve(y_test, y_proba_svm)
auc_svm = auc(fpr_svm, tpr_svm)
ax.plot(fpr_svm, tpr_svm, label=f'SVM (AUC={auc_svm:.3f})', linewidth=2)

# Diagonal (classificador aleatório)
ax.plot([0, 1], [0, 1], 'k--', label='Aleatório (AUC=0.5)', linewidth=1)

ax.set_xlabel('Taxa de Falsos Positivos')
ax.set_ylabel('Taxa de Verdadeiros Positivos')
ax.set_title('Curvas ROC - Comparação de Modelos', fontweight='bold')
ax.legend(loc='lower right')
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```

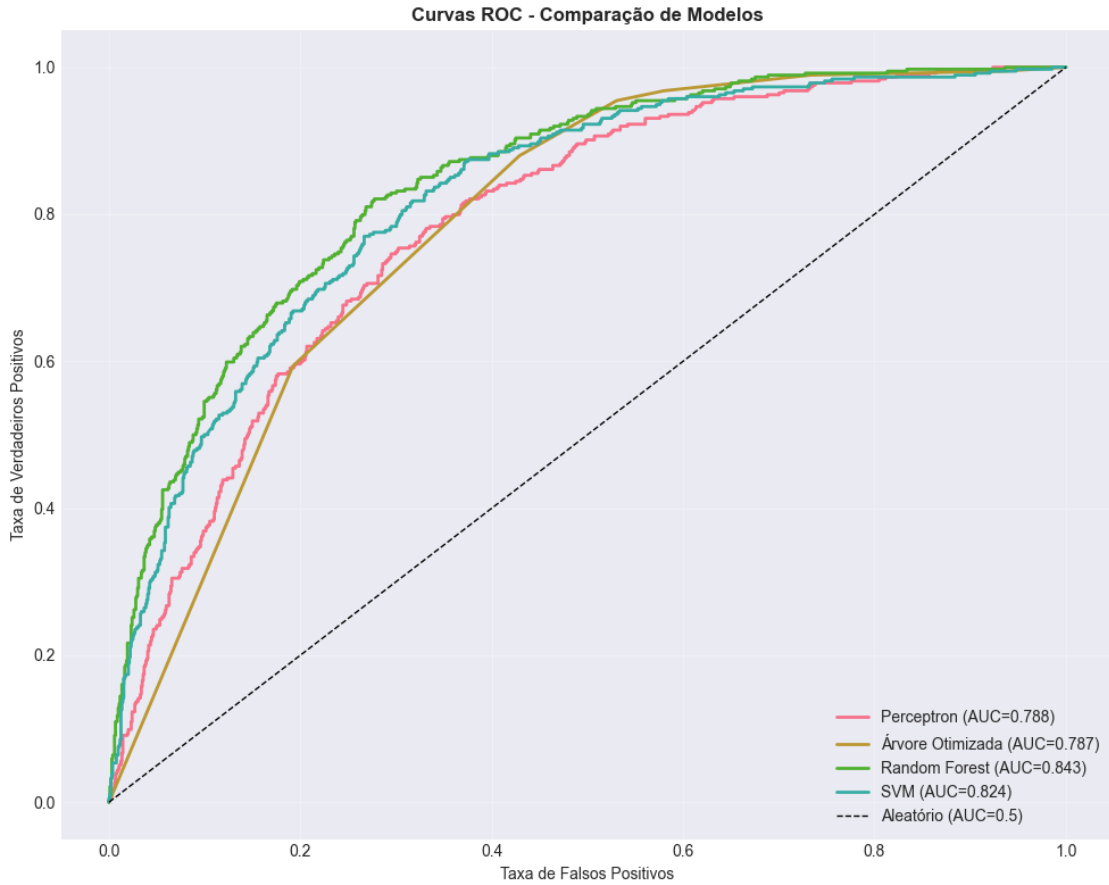

1.12 10. Conclusões e Recomendações

[22]:
```
print("\n" + "="*80)
print("ANÁLISE CRÍTICA E CONCLUSÕES")
print("="*80)

print(f"""
### 1. DESEMPENHO COMPARATIVO

O melhor modelo foi: {best_model_name}
  - F1-Score: {best_f1:.4f}
  - Accuracy: {models_comparison.loc[best_model_idx, 'Accuracy']:.4f}
  - Recall: {models_comparison.loc[best_model_idx, 'Recall']:.4f}
  - Precision: {models_comparison.loc[best_model_idx, 'Precision']:.4f}

### 2. GANHO DE COMPLEXIDADE vs. DESEMPENHO

Comparando Perceptron (simples, linear) com {best_model_name} (complexo,␣
↪não-linear):
```

```
  - Ganho em F1-Score: {(models_comparison.loc[best_model_idx, 'F1-Score'] -␣
↪f1_perc_test):.4f}
  - Ganho em Recall: {(models_comparison.loc[best_model_idx, 'Recall'] -␣
↪rec_perc_test):.4f}
  - Custo: Aumento significativo de complexidade e custo computacional

### 3. INTERPRETABILIDADE

  - Perceptron: ALTAMENTE interpretável (coeficientes lineares)
  - Árvore Otimizada: INTERPRETÁVEL (regras explícitas if-then-else)
  - Random Forest: POUCO interpretável (ensemble de árvores)
  - SVM: NÃO interpretável (hiperplano em espaço de alta dimensão)

### 4. GENERALIZAÇÃO

  - Perceptron: Underfitting leve (gap pequeno treino-teste)
  - Árvore Baseline: Overfitting severo (100% treino, {acc_dt_test:.1%} teste)
  - Árvore Otimizada: Generalização equilibrada
  - Random Forest: Boa generalização (ensemble reduz variância)
  - SVM: Boa generalização com kernel apropriado

### 5. RECOMENDAÇÃO PARA PRODUÇÃO

Para um sistema de retenção de clientes em produção, recomenda-se:

    MODELO: {best_model_name}
    - Melhor desempenho preditivo
    - Generaliza bem a dados novos
    - Captura padrões não-lineares complexos

    ALTERNATIVA (se interpretabilidade é crítica): Árvore Otimizada
    - Desempenho próximo ao melhor modelo
    - Regras explícitas justificáveis para negócio
    - Sem escalonamento de features necessário

### 6. PRÓXIMOS PASSOS

  1. Coletar mais dados para melhorar generalização
  2. Engenharia de features adicional (interações, polinômios)
  3. Balanceamento de classes (SMOTE, class_weight)
  4. Validação em dados fora da amostra (temporal split)
  5. Monitoramento de drift em produção
""")

print("\n" + "="*80)
print("ANÁLISE CONCLUÍDA COM SUCESSO")
print("="*80)
```

```
================================================================================
ANÁLISE CRÍTICA E CONCLUSÕES
================================================================================

### 1. DESEMPENHO COMPARATIVO

O melhor modelo foi: Random Forest
  - F1-Score: 0.5835
  - Accuracy: 0.8034
  - Recall: 0.5187
  - Precision: 0.6667

### 2. GANHO DE COMPLEXIDADE vs. DESEMPENHO

Comparando Perceptron (simples, linear) com Random Forest (complexo, não-
linear):
  - Ganho em F1-Score: 0.0273
  - Ganho em Recall: -0.0775
  - Custo: Aumento significativo de complexidade e custo computacional

### 3. INTERPRETABILIDADE

  - Perceptron: ALTAMENTE interpretável (coeficientes lineares)
  - Árvore Otimizada: INTERPRETÁVEL (regras explícitas if-then-else)
  - Random Forest: POUCO interpretável (ensemble de árvores)
  - SVM: NÃO interpretável (hiperplano em espaço de alta dimensão)

### 4. GENERALIZAÇÃO

  - Perceptron: Underfitting leve (gap pequeno treino-teste)
  - Árvore Baseline: Overfitting severo (100% treino, 72.5% teste)
  - Árvore Otimizada: Generalização equilibrada
  - Random Forest: Boa generalização (ensemble reduz variância)
  - SVM: Boa generalização com kernel apropriado

### 5. RECOMENDAÇÃO PARA PRODUÇÃO

Para um sistema de retenção de clientes em produção, recomenda-se:

    MODELO: Random Forest
     - Melhor desempenho preditivo
     - Generaliza bem a dados novos
     - Captura padrões não-lineares complexos

    ALTERNATIVA (se interpretabilidade é crítica): Árvore Otimizada
     - Desempenho próximo ao melhor modelo
     - Regras explícitas justificáveis para negócio
```

```
    - Sem escalonamento de features necessário

### 6. PRÓXIMOS PASSOS

  1. Coletar mais dados para melhorar generalização
  2. Engenharia de features adicional (interações, polinômios)
  3. Balanceamento de classes (SMOTE, class_weight)
  4. Validação em dados fora da amostra (temporal split)
  5. Monitoramento de drift em produção


================================================================================
ANÁLISE CONCLUÍDA COM SUCESSO
================================================================================
```